



## Evaluación de modelos de aprendizaje automático en el mercado financiero Forex.

**Mawrer Amed Ramírez Martínez, ms723737@iteso.mx**  
**J. Guadalupe Olascuaga Cabrera, jolascua@iteso.mx**  
**Luis Fernando Gutiérrez Preciado, lgutierrez@iteso.mx**

### Resumen

En este trabajo se analiza el mercado financiero Forex con el fin de predecir el precio futuro del tipo de cambio EUR/USD en base a los datos históricos y estadísticos por medio de distintos modelos de aprendizaje automático de forma supervisada. Este avance presenta un modelo de red neuronal recurrente de tipo LSTM (long short term memory) [2]. Se analizan las distintas características de entrada para posteriormente identificar que modelo da mejor resultados en el problema de la predicción.

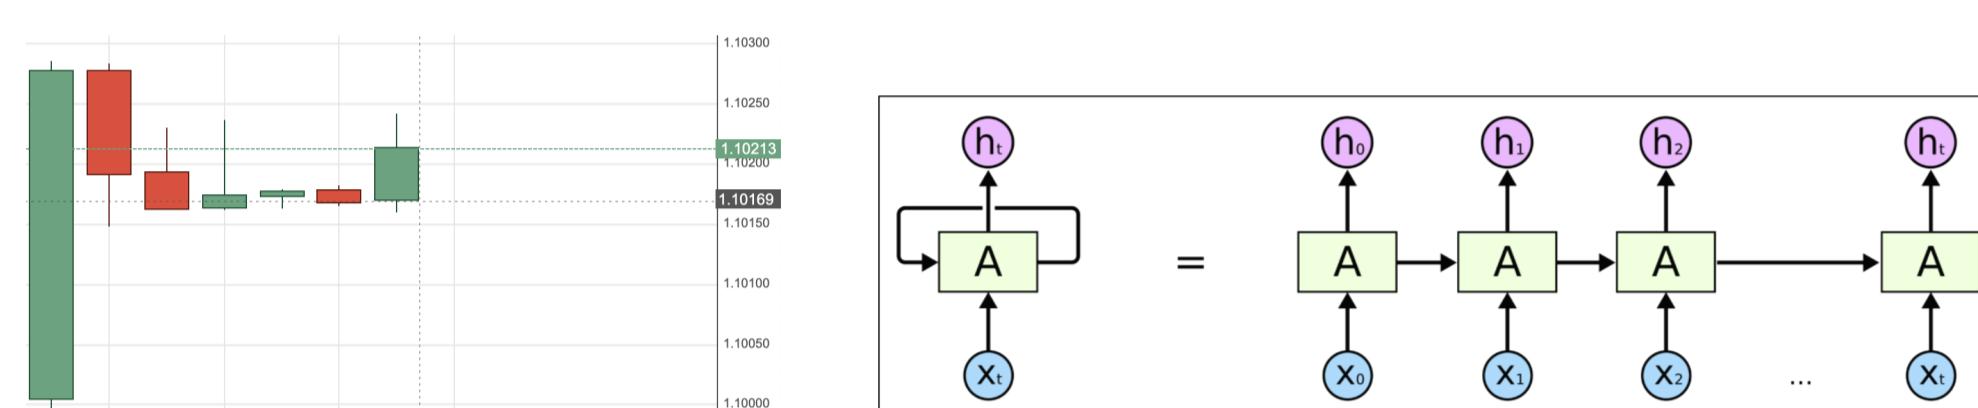


Figura izquierda- Gráfica ilustrativa de velas japonesas del tipo de cambio EUR/USD.  
 Figura derecha- Representación de una capa de una Red Neuronal Recurrente de tipo LSTM.

### Introducción y Descripción del Problema

El movimiento y variación del precio de compra y venta entre divisas no puede explicarse de una forma exclusiva, la cantidad de factores que influyen en el precio es difícil de identificar y medir, es por ello que es un tipo de problema complejo. Existen dos tipos de análisis en los mercados financieros[1]: Análisis Fundamental y Análisis Técnico. Este trabajo esta basado el análisis técnico.

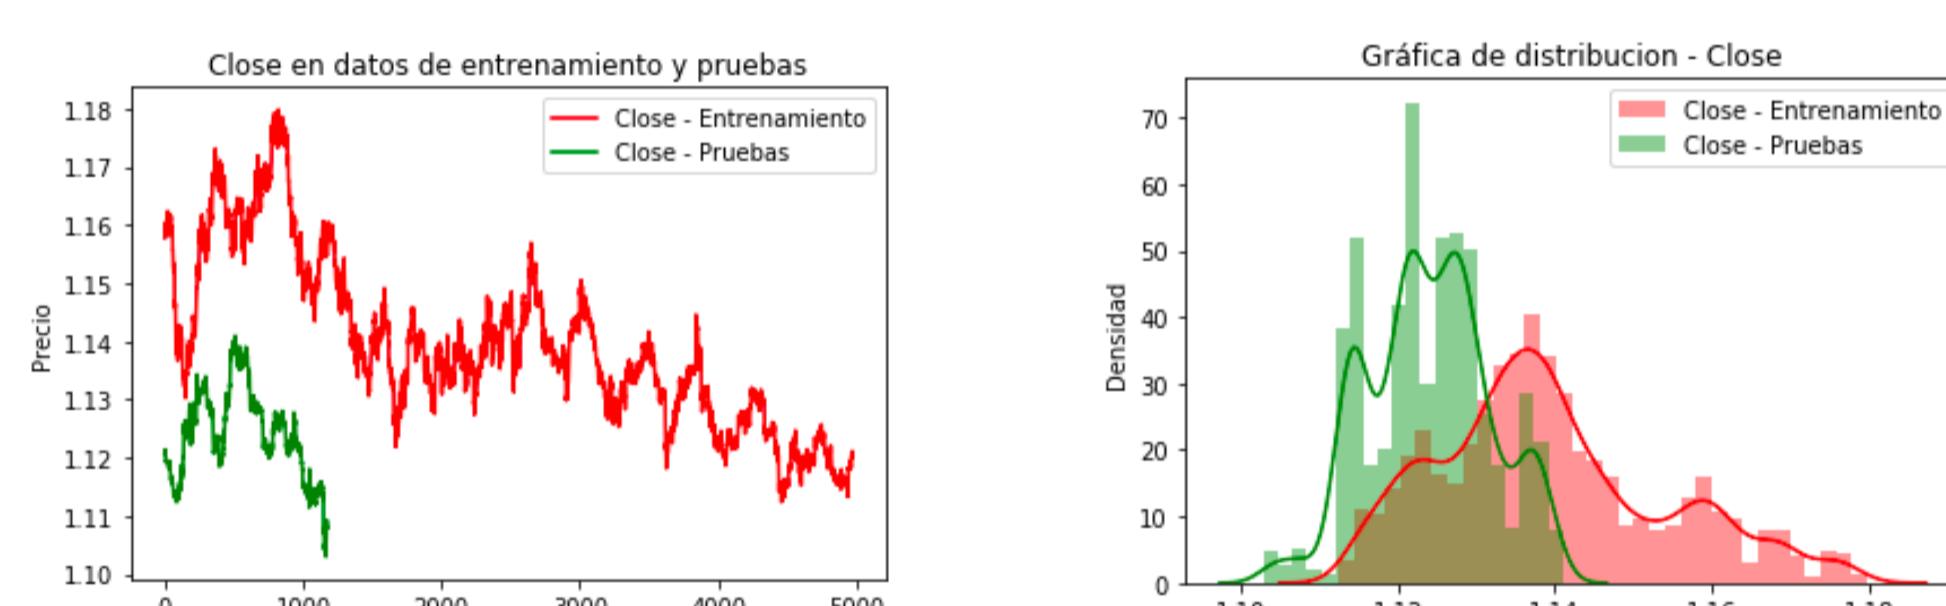


Figura izquierda- Gráfica del valor *Close* (*y*), datos de entrenamiento en azul, datos de pruebas en naranja.  
 Figura derecha- Representación de la distribución de '*y*' correspondiente a los datos de de entrenamiento.

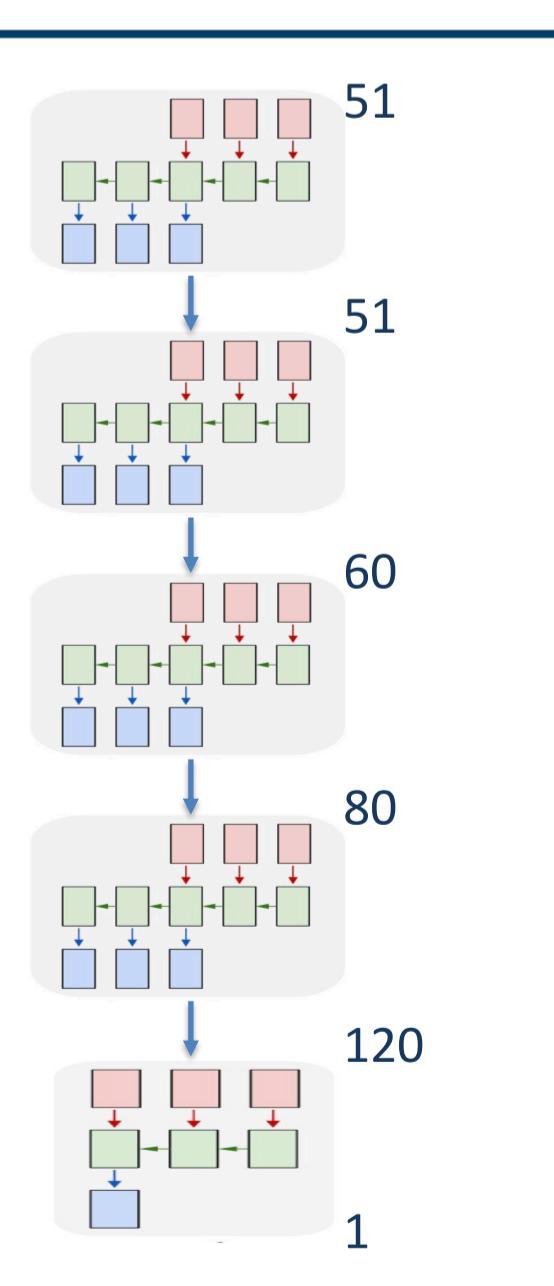
### Modelo Propuesto

#### Modelo RNN LSTM:

Layer (type)	Output Shape	Param #
lstm_28 (LSTM)	(None, 51, 51)	12036
lstm_29 (LSTM)	(None, 51, 60)	26880
lstm_30 (LSTM)	(None, 51, 80)	45120
lstm_31 (LSTM)	(None, 120)	96480
dense_7 (Dense)	(None, 1)	121
Total params: 180,637		
Trainable params: 180,637		

**Features iniciales:** High, Open, Low, Close, Volume.

**Features adicionales:** Promedio móvil 25 y 50.



### Agradecimientos

Agradezco al **Instituto Tecnológico y de Estudios Superiores de Occidente** (ITESO) por los recursos proporcionados para el desarrollo de este trabajo de obtención de grado.

Adicionalmente, agradezco al **Consejo Nacional de Ciencia y Tecnología** (CONACYT) por el apoyo económico recibido a través de la beca número 500498.

### Resultados Obtenidos

Con un entrenamiento de 100 épocas, utilizando un dataset equivalente a un año (01/08/2018 – 01/08/2019), con una frecuencia de 1H, una distribución entrenamiento/pruebas 80 20 y agregando un par de características adicionales de tipo promedio móvil (25 y 50).

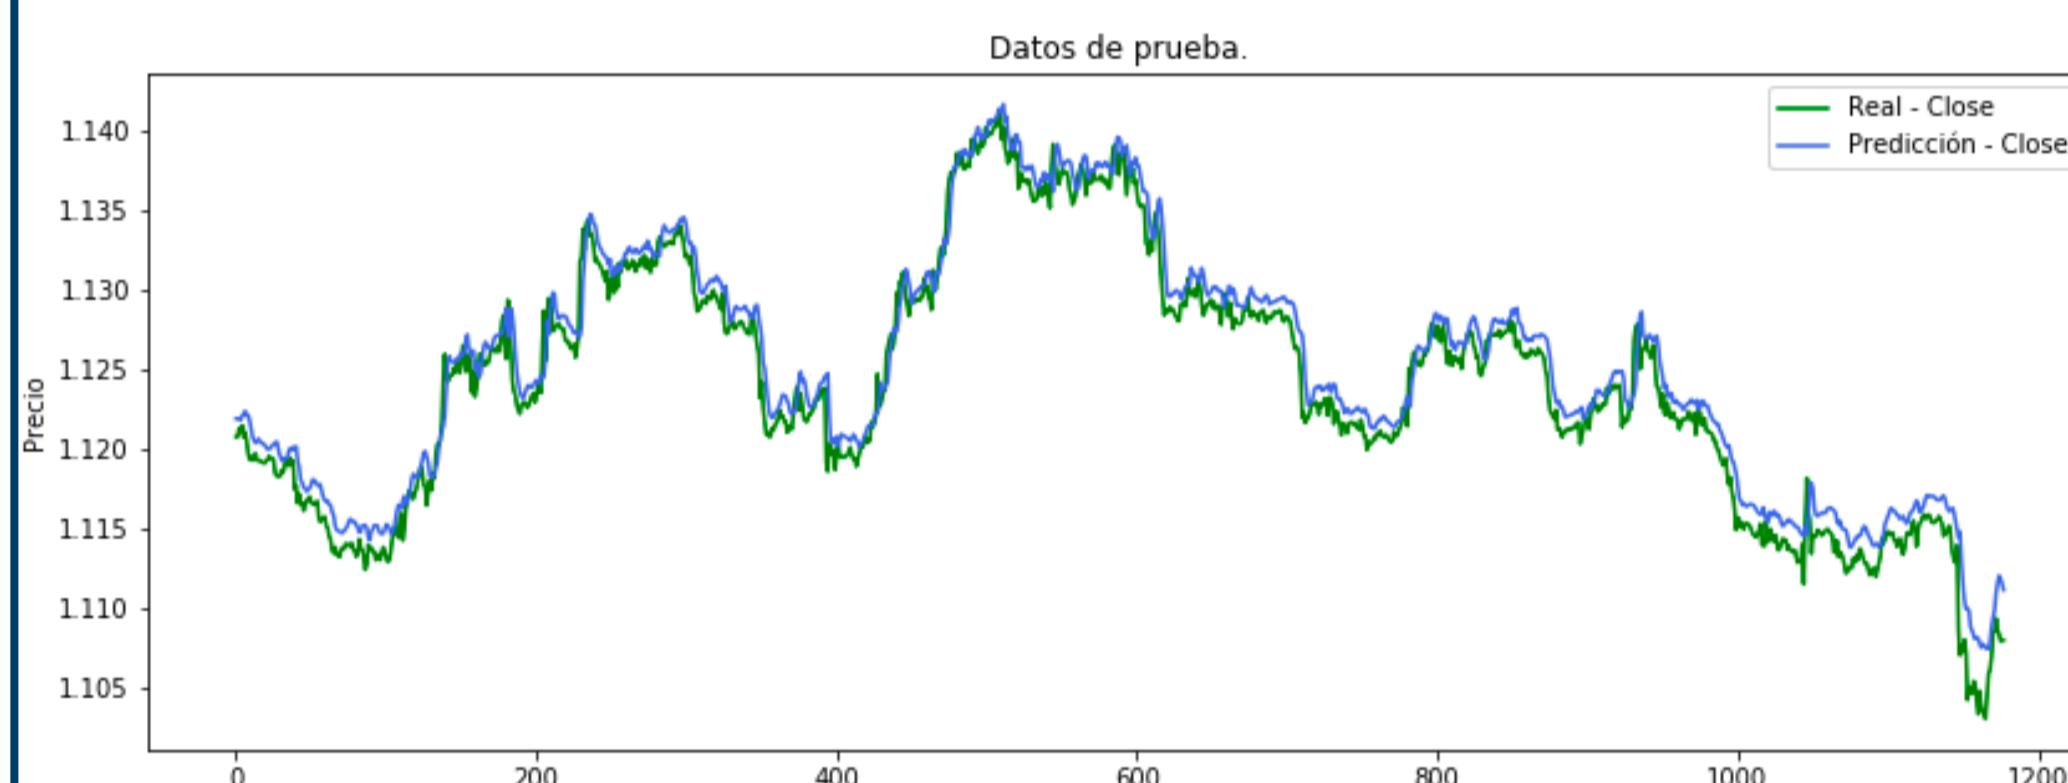
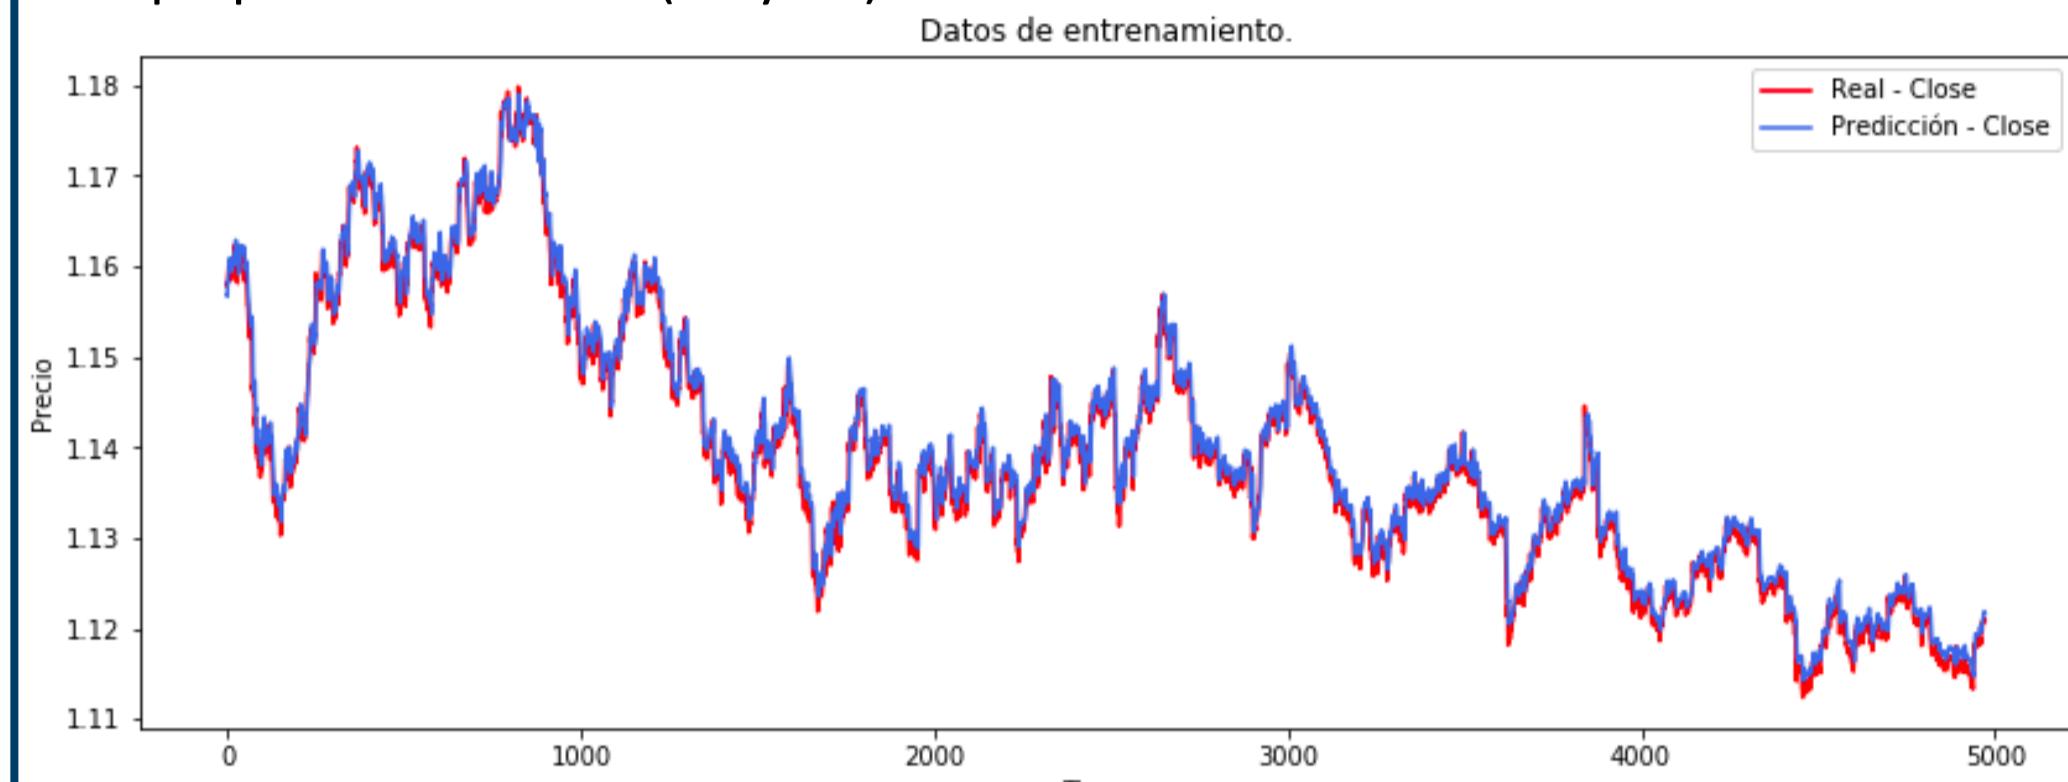


Figura 1 - Gráfica de datos de **entrenamiento** del valor *Close* comparados con la predicción obtenida.  
 Figura 2 - Gráfica de datos de **prueba** del valor *Close* comparados con la predicción obtenida.

### Conclusiones

LSTM es un modelo de RNN que por sus características nos permite realizar una relación directa en predicciones tomando como base un rango de datos anteriores.

El análisis y comprensión de los datos iniciales es una etapa fundamental para obtener resultados óptimos en la implementación de cualquier modelo de aprendizaje automático.

Para este problema descrito y con el modelo LSTM se identificó que el uso de un dataset de validación no mejoran las predicciones en el dataset de pruebas.

### Trabajo a Futuro

El modelo analizado basado en RNN-LSTM servirá como referencia para un análisis y comparación de múltiples modelos ya identificados (SVR, GRU y modelos Híbridos).

Respecto a nuevas características se deberá continuar el análisis de indicadores utilizados en los mercados financieros con el fin de probarlos en los distintos modelos de aprendizaje automático.

Se continuará explorando las ventajas del modelo LSTM y evaluar distintas arquitecturas.

### Referencias Significativas

- [1] Boming Huang, Yuxiang Huan, Li Da Xu, Lirong Zheng & Zhuo Zou (2018): Automated trading systems statistical and machine learning methods and hardware implementation: a survey.
- [2] Ian Goodfellow , Yoshua Bengio , Aaron Courville (2016). Deep Learning. ISBN : 9780262035613.
- [3] Park, J., and I. W. Sandberg. (1991). "Universal Approximation Using Radial-Basisfunction Networks." Neural Computation 3: 246–257. doi:10.1162/neco.1991.3.2.246.